

“ 배송 지연 분석을 통한 소비자 만족도 제고 프로젝트 ”

Olist 데이터를 활용한 배송 지연 요인 분석 및 개선 전략

8조 에잇이잇 > <

목차

01

프로젝트 개요

02

배송 지연 요인 분석
(회귀)

03

배송 지연 유형
(군집)

04

비즈니스 인사이트

05

한계점과 추가 분석
목표

1. 프로젝트 개요



OLIST

- 2015년도 설립된 브라질 쿠리치바 소재 전자상거래 플랫폼 기업
- 중소 판매자에게 상품 등록, 주문·물류 관리, 결제 통합 서비스 제공하여 온라인 비즈니스 성장을 지원하는 유니콘 스타트업



OLIST store dataset

- 2016년부터 2018년까지 브라질 여러 온라인 마켓플레이스에서 발생한 약 10만 건의 실제 주문 데이터
- 고객, 판매자, 상품, 주문, 결제, 배송, 각 주문에 대한 위치 정보, 리뷰 등으로 구성

1. 프로젝트 개요 - Olist Store Dataset

✔ 주요 컬럼

olist_orders_dataset
order_status
order_purchase_timestamp
order_approved_at
order_delivered_carrier_date
order_delivered_customer_date
order_estimated_delivery_date

olist_order_payments_dataset
payment_type
payment_value

olist_customers_dataset
customer_city
customer_state

olist_geolocation_dataset
geolocation_lat
geolocation_lng



olist_sellers_dataset
seller_city
seller_state

olist_products_dataset
product_weight_g
product_length_cm
product_height_cm
product_width_cm

olist_order_items_dataset
shipping_limit_date
price
freight_value

olist_order_reviews_dataset
review_score

1. 프로젝트 개요 - 배송 지연과 고객 만족도의 상관관계



1. 프로젝트 개요 - 배송 지연과 고객 만족도의 상관관계

목적: 지연 여부가 리뷰 점수(1~5)에 영향을 미치는지 검정 (검정 방법: 카이제곱 검정)

H0: 배송 지연 여부와 리뷰 점수는 독립이다

→ $\mu(\text{지연}) \neq \mu(\text{정상})$ 같은 평균이 아니라 분포 자체가 독립

H1: 배송 지연 여부와 리뷰 점수는 독립이 아니다.

→ 지연 여부에 따라 리뷰 점수 분포가 달라진다.

카이제곱 통계량: 16,799.9

p-value 0.000

Cramér's V = 0.42

1. 프로젝트 개요 - 분석 목표



회귀 분석 목표

배송 지연일의 영향을 미치는 요인을 찾는다.



군집 분석 목표

파악한 요인과 추가 변수를 넣어서 지연 유형을 분류하고 유형별 개선 전략을 도출한다.



분석 목표



배송 지연이 고객 평점에 미치는 영향을 분석하고, 관련 요인 개선을 통해 서비스를 향상시켜 고객 만족도를 높이는 방안을 도출한다.



회귀 분석 목표

배송 지연일의 영향을 미치는 요인을 분석한다.

2. 회귀 - 로그 변환



product_weight_g → log_product_weight_g
product_length_cm → log_product_length_cm
product_height_cm → log_product_height_cm
product_width_cm → log_product_width_cm
price → log_price
freight → log_freight
payment_value → log_payment_value

2. 회귀 - 파생변수

road_distance_km

위도·경도를 라디안으로 변환 → Haversine 함수를 적용 → 직선거리 × 1.26
(OSRM로 계산한 실제 도로거리를 직선거리로 나눈 값(약 1.26)을 보정계수로 활용)


계절성 / 주기성 파생 변수

배송 과정별 소요일수 산출
days_to_payment = 결제 승인일 - 주문일
days_to_ship = 배송 출발일 - 결제 승인일
days_until_limit = 배송 마감일 - 배송 출발일

계절·시간 패턴 반영 변수 추가
각 날짜(order_purchase_timestamp 등)에서 월(month), 요일(dayofweek), 시각(hour) 추출
불필요한 원본 날짜 컬럼 제거
→ delay_re.drop(columns = date_cols, inplace=True)
→ 시간 흐름과 계절적 요인을 함께 반영한 예측 변수 구축

2. 회귀 - 변수간 상관관계

상품 상관관계



상품 VIF

vif	
product_weight_g	1.992319
product_length_cm	1.542844
product_height_cm	1.483496
product_width_cm	1.639911



길이, 무게, 높이, 너비 상관관계
→ 중간정도

다중공선성 없음 ❌

2. 회귀 - 주와 지연여부 관계



카이제곱 독립성 검정

H_0 : 주와 지연여부는 평균은 독립적이다

H_1 : 주별 주와 지연여부는 독립적이지 않다

유의수준: $\alpha = 0.05$, 기대빈도 5 이하 셀 : 2

유의수준: $\alpha = 0.05$

카이제곱 통계량: 1952.22

p-value: 0.000

Cramér's V (효과 크기): 0.137048943939149

2. 회귀 - 스케일링 & 원핫인코딩



스케일링

'order_purchase_timestamp_month'	'log_price'
'order_purchase_timestamp_day_of_week'	'log_freight'
'order_purchase_timestamp_hour'	'log_product_weight_g'
'order_approved_at_month'	'log_product_length_cm'
'order_approved_at_day_of_week'	'log_product_height_cm'
'order_approved_at_hour'	'log_product_width_cm'
'order_delivered_carrier_date_month'	'log_payment_value'
'order_delivered_carrier_date_day_of_week'	'road_distance_km'
'order_delivered_carrier_date_hour'	'days_to_payment'
'shipping_limit_date_month'	'days_to_ship'
'shipping_limit_date_day_of_week'	'days_until_limit'
'shipping_limit_date_hour'	

원핫인코딩

'payment_type'
'seller_state'
'customer_state'

2. 회귀 - ols 결과



모델 성능

$R = 0.2 \rightarrow$ 설명력 낮음

$RMSE = 6.2 \rightarrow$ 실제 지연값과 차이는 작지만 예측력 제한

결론: 참고용 분석 수준, 실제 예측에는 한계

2. 회귀 - 중요 변수

연속형 변수

- 배송 마감일·주문 승인 월이 특정 월일수록 배송 지연 ↑
→ 시즌·계절적 요인 영향
- 배송 마감 대비 출고 여유일 ↑ → 지연 ↓ (가장 강한 신호)

범주형 변수

- 주문/판매 지역(State)이 가장 큰 영향
- customer_state_PA → 배송 지연 ↑
- seller_state_PB → 배송 지연 ↓
- 결제 수단(payment_type) 영향은 미미

2. 회귀 - 트리 모델 회귀 분석

RandomForestRegressor
GradientBoostingRegressor
XGBRegressor
LGBMRegressor



- 로그 복원: Tree에서는 원래 값 사용 (OLS는 로그 변환 상태 사용)
- 스케일링: Tree는 스케일링 안함 (OLS는 StandardScaler 적용)

CatBoostRegressor

- 로그 복원: Tree에서는 원래 값 사용 (OLS는 로그 변환 상태 사용)
- 스케일링: Tree는 스케일링 안함 (OLS는 StandardScaler 적용)
- 인코딩 안함
- seller_city와 customer_city 추가

Model	R2	RMSE
RF	0.41	5.47
GB	0.32	5.59
XGB	0.40	5.53
LGBM	0.40	5.58
CatBoostRegressor	0.43	5.34

2. 회귀 - 트리 모델 회귀 분석



OLS와 공통

배송마감대비 출고 여유일(days_until_limit)이 짧을수록 지연 ↑ (가장 강한 신호)
마감일, 주문 승인 특정 월에서 지연 ↑ 피크월일 때 지연일 ↑

하이퍼 파라미터
→ RandomizedSearchCV로 선정

평가지표
→ 최적 RMSE (훈련 셋 기준): 5.29
→ 테스트 RMSE: 5.26
→ 테스트 R^2 : 0.466

→ 약 46.6%의 지연일 변동



군집 분석 목표

파악한 요인과 추가 변수를 넣어서 지연 유형을 분류하고 유형별 개선 전략을 도출한다.

3. 군집


전체 데이터 vs 지연 데이터

분석 목적

- 전체 평균이 아닌 '지연 발생 패턴'의 구조적 원인을 찾기 위함

데이터 구조

- 전체의 93% 이상이 정상 배송, 군집 시 지연 특성 희석




3. 군집

배송 신뢰도를 구성하는 세 가지 단계

OLS회귀로 찾은 핵심 요인

출고 단계



“ 출고 여유일 ”

출고 마감일 - 판매자 출고일


배송 단계



“ 지역 내 거래 비율 ”

동일 지역 내에서 거래되는 비율


도착 단계



“ 지연일수 ”

실제 배송 도착일 - 예상 배송 도착일


3. 군집



군집별 주요 결과

Clurster	출고여유일	지역내 거래 비율	배송지연일
장거리지연형	2.2일	0.025	9.1일
경미지연형	1.4일	0.035	3.5일
출고지연형	1.3일	0.898	5.8일

3. 군집



✓ 장거리지연형 (51.5%)

- 출고 여유가 있음에도 배송이 늦은 것은 물류망(운송 경로, 허브 위치) 문제 가능성이 큼
- 즉, 운송 프로세스 효율 저하 또는 물류 거점 불균형이 지연의 원인

✓ 경미지연형 (28.3%)

- 장거리 운송 중 외부 요인(거리, 교통, 기상, 지역 간 물류 인프라 차이)에 영향을 받음

✓ 출고지연형 (20.2%)

- 같은 지역 내 거래인데도 지연이 발생 → 운송보다는 판매자 측 출고 지연이 원인일 가능성
- 재고 부족, 판매자 관리 부실 등 운영·공급단 문제가 시사됨

4. 인사이트 및 기대효과



장거리 지연형


물류 파트너 간 SLA(운송 품질 계약) 재검토를 통한 운송 단계 단축



경미 지연형

셀러 관리 정책 강화:
출고 지연률이 높은 셀러에 경고·패널티 부과

교육 및 인센티브 제공:
정시 출고율이 높은 셀러에게 가시적 보상 제공



출고 지연형

재고 예측 기반 출고 프로세스 개선:
인기 상품은 지역 내 사전 재고 확보

로컬 신규 판매자 유입:
해당 지역 내 셀러 비율을 높여 거리를 단축하고, 배송 안정성 개선

한계점

감사합니다 :D

에잇이잇><